

אלגוריתמים בביולוגיה חישובית – תרגיל 1

מגשים:

יהונתן עזרא - 206762163

יאיר מחפוד - 207807082

שאלה 1

יהי $s = s_1 \dots s_n$ ו- $t = t_1 \dots t_n$ נרצה להראות כי מספר העימודים האפשריים של s מול t הוא לפחות אקספוננציאלי ב- n :

נבחין כי העימוד המלא ביותר בין שני רצפים באורך n יכול לכלול לכל היותר $2n$ עמדות שכן ייתכנו רווחים משני הצדדים של כל אות בכל רצף. נניח ללא הגבלת הכלליות שאנחנו בוחרים את מיקומי האותיות s בין $2n$ בעמדות האפשריות בעוד שמיקומי האותיות t נקבעים בהתאם באופן משלים.

לפיכך, קל לראות שהבעיה שקולה לבחירת n מיקומים מתוך $2n$ אפשריים, כלומר $\binom{2n}{n}$ שזה ביטוי אקספוננציאלי ב- n . למעשה כל עמודה בעימוד שלנו יכול להראות אחד משלושת המקרים הבאים:

תו s ומתחתיו רווח

רווח ומתחתיו תו t

תו s ומתחתיו תו t

ולכן למעשה זה כמו לבחור בכל מיקום האם לשים רווח או את התו, שזה כמו שאמרנו בעיה מוכרת בקומבינטוריקה לבחירת n מקומות מתוך $2n$ אפשריות.

שאלה 2:

הסבר מה עשינו:

יהי סדרה $X = x_1 \dots x_n$ ונרצה לבצע סגמנטציה אופטימלית למקטעים עוקבים כל שתתקבל חלוקה למספר סגמנטים k באופן שימזר את סכום השגיאות הריבועיות בתוך כל סגמנט כאשר אנחנו משלים קנס p עבור כל סגמנט חדש. במילים אחרות אנחנו רוצים מזר את

$$\arg \min \sum_{i=1}^n (x_i - u_j)^2 + k + p$$

לצורך הפתרון הגדרנו את פונקציה העלות הכוללת הבאה:

1) $c[i] = \min(c[m] + \text{SSE}(m,i) + p)$ כאשר $c[i]$ זה עלות עבור הסגמנט של i המספרים הראשונים ו $\text{SSE}(m,i)$ זה סכום הריבועים של השגיאות בסגמנט $m+1, \dots, i$. p זה קנס עבור כל סגמנט.

נגדיר את תנאי ההתחלה $C[0]=0$ ובסיום הפתרון הכולל יהיה C_n המייצג את העלות הסגמנטציה האופטימלית של כל הסדרה.

על מנת להמנע מחישובים חוזרים, השתמשנו ב: prefix sums:

$$S_i = \sum_{k=1}^i x_k$$

$$Q_i = \sum_{k=1}^i x_k^2$$

ואז למעשה עבור כל אינטרוול $[a,b]$ אנחנו נקבל:

$$\text{SSE}(a,b) = Q[b] - Q[a] - 2u(S[b] - S[a]) + (b-a)u^2, \text{ where } u = (S[b] - S[a]) / (b-1)$$

מבנה האלגוריתם:

1) אתחול:

ניצור שני מערכים בגודל $n+1$

• C_i = עלות מינימלית עד לאיבר i ,

• T_i - נדקס ההתחלה של הסגמנט האחרון (לצורך שחזור הפתרון).

(2) מילוי טבלת הדינמיקה:

עבור כל i נמלא בצורה הבאה: $c[i] = \min(c[m] + \text{SSE}(m,i) + p)$ 1

(3) שחזור הפתרון:

נתחיל מהאינדקס $i=n$ ונשתמש ב T כדי לחזור אחורה עד תחילת הסדרה

סיבוכיות:

סיבוכיות זמן - בכל צעד i נבחנו לכל היותר q מועמדים למ ולכן $O(nq) + O(n) + O(k) = O(nq)$ (במידה ולא מגבילים את q) $O(n^2)$

סיבוכיות מקום: האלגוריתם דורש $O(n)$ מקום לזיכרון שני המערכים T ו- C ושני הוקטורי $prefix$ ולכן סך הכל זה $O(n)$


בנוסף:

במקרה בו X היא מטריצה בגודל $d \times n$ כל שורה מייצגת ערוץ שונה אך כל הערוצים מחולקים לאותם גבולות סגמנטים. ולכן במקרה זה פונקציית העלות מתעדכנת כך שכל הערוצי d נכללים:


$$C[i] = \min (C[m] + \sum_{r=1}^d SSEr(m, i) + p)$$

תוצאות גרפים על משתנים שונים:


:penalty 0.15 --max_len 100




penalty 0.1 --max_len 50:



penalty 0.00000001 --max_len 100:



--penalty 1000 --max_len 1000:



penalty 1 --max_len 100000:

